Business Intelligence – Lab 1

24/02/2026 – EPF – A. CHARLEMAGNE

# Task 1 : Choose a Dataset

*What business problem is your client facing?*

Le client est un constructeur qui souhaite se lancer dans l'électrique et qui veut comprendre quels sont les critères pour maximiser la durée de vie de la batterie.

*Why do they need a BI solution?*

Une solution de Business Intelligence est nécessaire car la dégradation des batteries dépend de plusieurs facteurs en même temps (température, charge rapide, cycles, style de conduite, etc.).

Un simple tableur ne permet pas de comprendre facilement les liens entre ces données.

La BI permet :

- d'identifier les corrélations entre les variables,
- de visualiser les tendances de dégradation dans le temps,
- et d'analyser automatiquement des milliers de véhicules.

En résumé, on a besoin d'une solution BI pour obtenir une analyse claire, globale et exploitable des données.

*What data is available, and why is it insufficient in its current state?*

Ces paramètres décrivent l'identité du véhicule, les caractéristiques techniques de sa batterie, son usage (âge, cycles, température, charge rapide, style de conduite), ainsi que des indicateurs de dégradation afin d'estimer son état de santé (SoH) et déterminer si la batterie est encore saine ou doit être remplacée.

C'est insuffisant dans l'état actuel car on ne peut pas faire de liens entre chaque paramètres et déterminer quel est le paramètre qui détériore la batterie.

*What type of decisions should this dashboard help to make ?*

Problem solving, Maintenance, Best type of battery

*Add to your file the Target User:*

L'utilisateur cible sera le département d'ingénierie du constructeur. Nous travaillons dans une société de conseil en données, ils doivent donc répondre à certaines questions sur la durabilité de la batterie en fonction de différents critères. Leur niveau d'expertise en matière de données n'est pas très élevé, c'est pourquoi ils font appel à nos services. Ils auront besoin d'une vue d'ensemble pour passer à une gestion plus prédictive et être en mesure de concevoir une batterie performante pour leurs nouveaux modèles électriques.

**Source du dataset :**
https://www.kaggle.com/datasets/bertnardomariouskono/electric-vehicle-ev-battery-degradation-and-charge/data

Le DataSet contient 10 000 lignes.

## Table 1 : Véhicule

- Vehicle_ID (clé primaire)
- Car_Model
- Vehicle_Age_Months

## Table 2 : Batterie

- Battery_ID (clé primaire)
- Battery_Type
- Battery_Capacity_kWh

## Table 3: Usage_Data

**Attributs :**

- Usage_ID (clé primaire)
- Total_Charging_Cycles
- Avg_Temperature_C
- Fast_Charge_Ratio
- Avg_Discharge_Rate_C
- Driving_Style

## Table 4 : Battery_Health

**Attributs :**

- Health_ID (clé primaire)
- Internal_Resistance_Ohm
- SoH Percent
- Battery Status

## Column dictionary :

- Vehicle_ID : identifiant unique pour chaque véhicule.
- Car_Model : modèle spécifique du véhicule électrique (par exemple, Tesla Model 3, BYD Atto 3).
- Battery_Type : composition électrochimique de la batterie (LFP ou NMC).
- Battery_Capacity_kWh : capacité totale de stockage d'énergie de la batterie.
- Vehicle_Age_Months : Durée écoulée depuis la fabrication du véhicule.
- Total_Charging_Cycles : Nombre cumulé de cycles de charge-décharge complets.
- Avg_Temperature_C : Température moyenne de fonctionnement de la batterie (cruciale pour la dégradation).
- Fast_Charge_Ratio : proportion des sessions de charge effectuées via une charge rapide en courant continu (0,0 à 1,0).
- Avg_Discharge_Rate_C : taux moyen de décharge d'énergie pendant la conduite (indicateur de l'agressivité au volant).
- Driving_Style : étiquette catégorielle (prudent, modéré, agressif).
- Internal_Resistance_Ohm : impédance interne de la batterie ; augmente à mesure que le SoH diminue.
- SoH_Percent : (cible 1) état de santé. Capacité actuelle en pourcentage de la capacité d'origine.
- Battery_Status : (cible 2) étiquette de classification (en bon état ou à remplacer).

The perceived data quality is really good. There are no duplicates and no NaN values.

# Task 2 : Define the business need

**Secteur :** Automobile / Véhicules électriques
**Utilisateur cible :** Département d'ingénierie du constructeur

Problème à résoudre :
Le client souhaite comprendre quels facteurs causent la dégradation des batteries des véhicules électriques afin d'optimiser leur durée de vie et de concevoir des batteries plus durables.

Utilisateur final :
Le département d'ingénierie du constructeur automobile, dont l'expertise en matière de données est limitée.

Décisions à prendre :

Identifier les conditions d'utilisation (température, habitudes de recharge, style de conduite) qui ont un impact sur la durée de vie des batteries.

Améliorer la conception des batteries pour les futurs modèles de véhicules électriques.

Planifier de manière proactive des stratégies de maintenance ou de remplacement.

Indicateurs clés de performance (KPI) nécessaires :

- État de santé (SoH_Percent)
- État de la batterie (en bon état / remplacement nécessaire)
- Nombre total de cycles de charge
- Taux de charge rapide
- Température moyenne
- Taux de décharge moyen
- Style de conduite

L'enjeu est de traduire des milliers de points de données brutes (température, cycles…) en évidences techniques pour permettre au département d'ingénierie de :

- **Ajuster la partie technique :** Déterminer avec certitude si l'effort de R&D doit se concentrer sur le système de refroidissement (sensibilité à la température) ou sur la chimie des cellules (sensibilité aux cycles de charge rapide).
- **Isoler les variables importantes :** Sortir des suppositions pour identifier mathématiquement des facteurs déclencheurs.
- **Standardiser la Longévité :** Établir des profils de référence pour les futurs modèles.

# Task 3: Write the requirements/specifications document

## 1. Context & objective

Un constructeur automobile qui se lance dans l'électrique souhaite comprendre quels facteurs influencent la dégradation des batteries. Le département d'ingénierie, avec une expertise limitée en données, est l'utilisateur principal.
Ils veulent identifier les conditions qui réduisent la durée de vie des batteries : température, style de conduite, habitudes de recharge, etc.
L'objectif est d'avoir une vue d'ensemble claire pour prendre des décisions éclairées. Ils souhaitent améliorer la conception des batteries pour les futurs modèles électriques.
Le dashboard doit aussi permettre de planifier la maintenance et le remplacement des batteries de manière proactive.
Les KPI nécessaires incluent : SoH_Percent, Battery_Status, nombre de cycles de charge, taux de charge rapide, température moyenne, taux de décharge et style de conduite.
Une solution BI est nécessaire pour lier toutes ces variables et révéler des tendances invisibles dans un simple tableur.
L'analyse permettra de passer d'une gestion réactive à une gestion prédictive de la durabilité des batteries.
En fin de compte, le projet aidera à concevoir des batteries plus fiables et performantes pour les véhicules électriques.

## 2. Scope (In scope / Out of scope)

**In scope :**

- Analyser les facteurs qui influencent la dégradation des batteries (température, style de conduite, cycles de charge, taux de charge rapide).

- Concevoir un dashboard BI pour visualiser l'état des batteries et les tendances de dégradation.

- Fournir une synthèse claire pour le département d'ingénierie afin d'optimiser la conception des batteries et planifier la maintenance.

**Out of Scope :**

- Collecte directe des données sur les véhicules ou les batteries (nous utilisons le dataset existant).
- Prévisions financières ou recommandations marketing.
- Analyse des batteries d'autres constructeurs.

## 3. Planned KPIs + Definitions

**1. State of Health (SoH_Percent)**

- Définition : Capacité actuelle de la batterie en pourcentage de sa capacité d'origine.

**2. Battery_Status**

- Définition : État de la batterie selon le seuil de SoH.

**3. Total_Charging_Cycles**

- Définition : Nombre cumulé de cycles complets charge-décharge.

**4. Fast_Charge_Ratio**

- Définition : Proportion des sessions effectuées en charge rapide DC.

**5. Avg_Temperature_C**

- Définition : Température moyenne de fonctionnement de la batterie.

## 4. Data Used

**Tables :**

1. Vehicle : Vehicle_ID, Car_Model, Vehicle_Age_Months
2. Battery : Battery_ID, Battery_Type, Battery_Capacity_kWh
3. Usage_Data : Usage_ID, Total_Charging_Cycles, Avg_Temperature_C, Fast_Charge_Ratio, Avg_Discharge_Rate_C, Driving_Style

4. Battery_Health : Health_ID, Internal_Resistance_Ohm, SoH_Percent, Battery_Status

**Granularity :**

- 1 ligne = 1 véhicule (résumé global de l'usage et de l'état de la batterie)

**Possible Limitations :**

- Pas de suivi temporel précis pour chaque charge (historique limité)
- Dataset simulé, peut ne pas refléter toutes les conditions réelles

# 5. Identified Constraints

- **Data quality :** Bonne qualité, pas de doublons ni de valeurs manquantes.
- **Volume :** 10 000 lignes, manipulable avec un BI tool.
- **Missing values :** Aucune valeur manquante détectée.
- **Units / dates / data types :**
    - Température en °C
    - SoH en %
    - Battery_Type et Driving_Style catégoriels
    - Internal_Resistance en Ohm
    - Vehicle_Age en mois

# Task 1: Write User Stories

As an Engineer, I want to see the rate of battery capacity above 95% after 5 years so that I can monitor durability.

- Dashboard needs to display the proportion of batteries having a State of Health above 95% at Year 5.
- It must have the possibility to display the evolution of the proportion of batteries having a State of Health above 95% for the first 5 years (from year 1 to year 5).

As a Marketing Manager, I want to know which driving style is the best for battery health and durability so that I can adapt the image of the brand and our client target.

- The dashboard should display battery performance based on different driving styles ( Aggressive, Conservative, Moderate)

As a Project Manager, I want to know which type of battery has the best durability/state of health having a Fast Charge Ratio above 50%.

- The dashboard must filter batteries with a Fast Charge Ratio greater than 50%.
- It must display the battery type and its average state of health compared to the number of recharging cycles.

As an Engineer, I want to predict the current State of Health (SoH) of a battery based on its usage history and temperature so that I can anticipate performance issues and plan maintenance.

- The dashboard should use historical usage data and temperature readings to estimate current health status.
- The predicted health status should be displayed as a percentage on a clear KPI card.

# Task 2: Agile Backlog

## User Story 1

As an Engineer, I want to see the rate of battery capacity above 95% after 5 years so that I can monitor durability.

Related Technical Tasks:

1. **Ingestion:** Collect historical battery data (SoH, cycles, dates) from BMS.

2. **Transformation:**

    Clean and filter data for batteries with valid 5-year history.
    Calculate yearly SoH and proportion of batteries >95%.

**3. Modelling**:

Create a data model with Year 1 → Year 5 SoH values.
Compute trend of battery capacity above 95%.

**4. Reporting:**

Design line chart showing evolution over 5 years.
Display KPI card for proportion at Year 5.
Add filters by battery type, site, or model

## User Story 2

As a Marketing Manager, I want to know which driving style is the best for battery health and durability so that I can adapt the image of the brand and our client target.

**Related Technical Tasks:**

**Ingestion:**

- Collect battery performance data tagged by driving style (Aggressive, Moderate, Conservative).

**Transformation:**

- Aggregate battery SoH and degradation by driving style.

**Modelling:**

- Create a model comparing average SoH and durability per driving style.

**Reporting:**

- Design bar or line charts showing battery performance per driving style.

## User Story 3

As a Project Manager, I want to know which type of battery has the best durability/state of health having a Fast Charge Ratio above 50%.

**Related Technical Tasks:**
**Ingestion:**

- Import battery data including Fast Charge Ratio, SoH, cycles, and type.

**Transformation:**

- Filter batteries with Fast Charge Ratio > 50%.
- Calculate average SoH per battery type and cycle count.

**Modelling:**

- Build comparative model of battery type vs. average SoH and cycles.

**Reporting:**

- Create bar/column chart comparing battery types.
- Display KPI cards for best-performing battery types.

# Task 3: Conceptual modelling

We were thinking about 4 different tables :
- Battery
- Vehicule
- Battery Health
- Usage Data

1. What seems to be your main activity table?

The main table appears to be the Battery Health table because it contains the SoH (Status of Health) and Battery Status

2. Which tables describe things?

The tables Battery and Vehicule describe things.

3. What information will need to be cleaned or harmonized?

At first, it seems that the dataset is 100% usable in its actual state.

4. What information may need to be grouped or transformed?

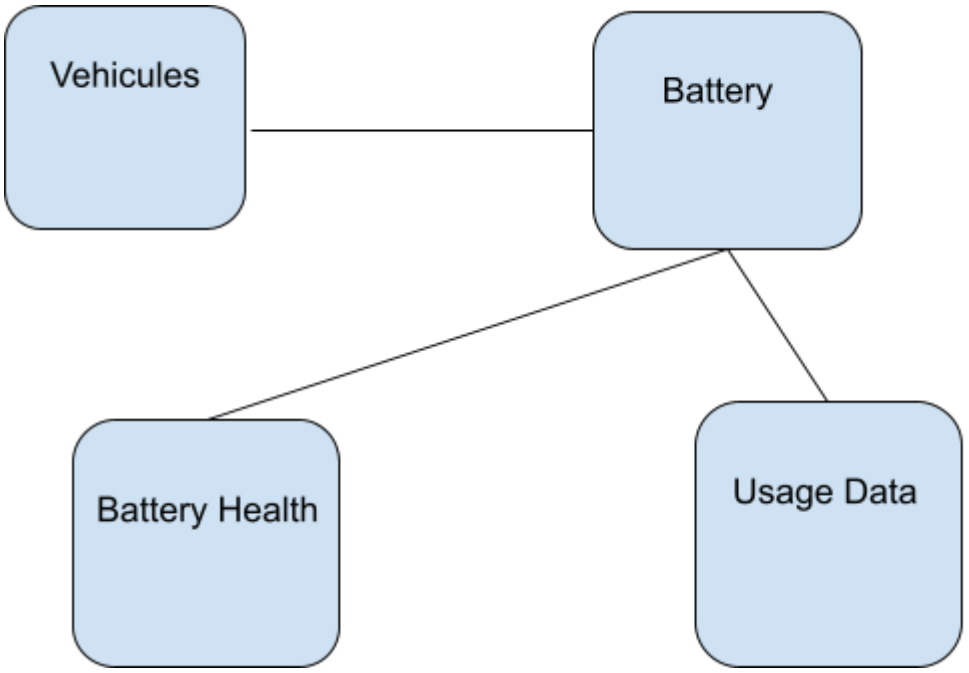
Certaines informations peuvent être regroupées afin de faciliter l'analyse :

- **Vehicle_Age_Months** → convertir en années ou en tranches d'âge (0–2 ans, 3–5 ans, etc.)
- **SoH_Percent** → regrouper en catégories (Excellent, Bon, Moyen, Critique)

- **Fast_Charge_Ratio** → regrouper en faible / moyen / élevé
- **Avg_Temperature_C** → classer en basse / normale / élevée
- Calculer un **taux de dégradation** (ex : perte de SoH par année)
- Calculer des **moyennes par groupe** (par type de batterie, style de conduite, etc.)

Ces transformations permettent une analyse plus claire dans le dashboard.

Draw a first simple conceptual schema/model




5. Which tables feel connected? (intuitive only)

Table (Battery) ↔ Table (Battery_Health)

Table (Battery) ↔ Table (Usage_Data)

Table (Batterie) ↔ Table (Vehicules)

# LAB 3

For the moment, we have selected the following components :

- Notebook
- Lakehouse

**Lakehouse** → This is the project's central storage. It contains the three layers—Bronze, Silver, and Gold—in the form of Delta tables, and Power BI can connect to it directly via OneLake.

**Notebook** → This is where all the transformation work is done in Python/PySpark. We use it to ingest the Excel file into the Bronze layer, clean the data in the Silver layer, and then prepare the business tables in the Gold layer.

**Dataflow Gen2** → Its role is to ingest data via a visual, code-free interface. Since we already load the Excel file directly into the Notebook using pandas, it would be redundant and adds no additional value in our case.

**Warehouse** → The Warehouse is useful when multiple teams need high-performance SQL access to large volumes of data. In a hands-on exercise with a single dataset, the Lakehouse fulfills exactly the same role for Power BI, without any additional complexity.

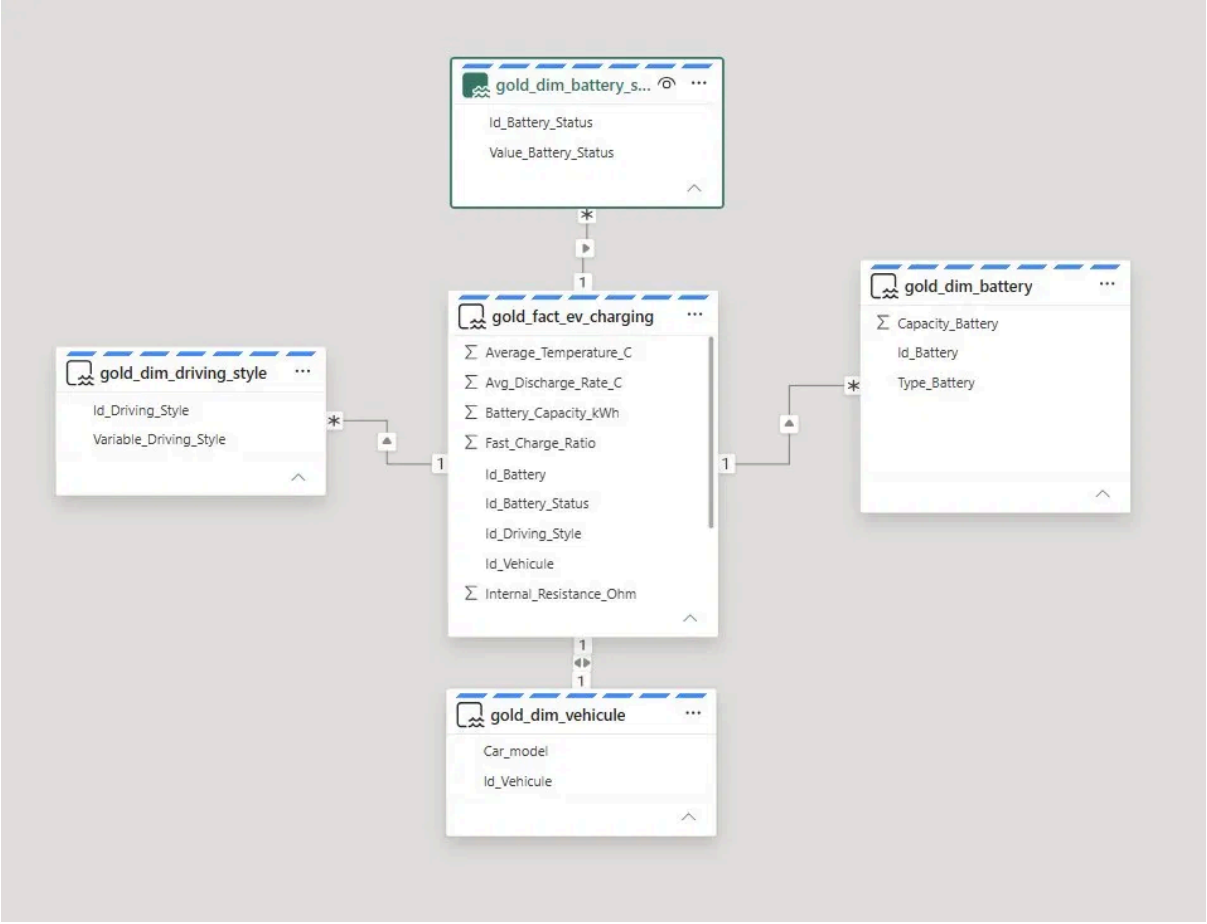
**Data Pipeline** → The Pipeline is used to orchestrate and automate the execution of Notebooks according to a schedule or defined sequence. During the development phase, we run the Notebooks manually, so it is not necessary at this stage.

To summarize

-> The Lakehouse allows us to stock our raw data. The Notebook permits the transformation of the data.

**Choices of relations :**

| Parameter | What to Choose | Why? |
|---|---|---|
| Cardinality (Vehicle ↔ Facts) | 1:1 (One-to-one) | A unique vehicle in the dimension corresponds to only one row in the fact table at time T. |
| Cardinality (Other Dimensions ↔ Facts) | *:1 (Many-to-one) | One dimension value (e.g., “NMC” battery type) can be associated with several different vehicles in the fact table. |
| Cross-filter direction | Single | The filter should flow from the Dimension table to the Fact table. |




Star schema